

Matriz de Revisão Detalhada — Plano de Ação (Pós-ASE 2026)

Submissão #2166 — MARTA: A Decoupled Multi-Agent Architecture for Python Test Generation. Resposta ponto a ponto (frase a frase) a cada comentário dos revisores. A coluna "Tarefa" liga cada comentário às tarefas consolidadas (ver 2ª tabela), evidenciando as que respondem a mais do que uma questão.

Rev.	Comentário do Revisor (frase a frase)	Plano de Ação (Solução / Resposta no Artigo)	Tarefa
A	"poor evaluation, in design, execution, and reporting/presentation"	Reestruturar completamente a secção de Avaliação (Secções 4 e 5), detalhando setup experimental, métricas e apresentação visual. Endereçado transversalmente pelas tarefas abaixo.	Transversal (T1,T3,T4,T5,T6)
A	"test generation is limited to regression tests, i.e., it does not really go beyond existing approaches (both traditional and LLM based)"	Declarar abertamente como limitação na Discussão: sem oráculo de especificação, a MARTA captura o comportamento atual do código (testes de regressão), tal como as ferramentas que a originaram. Clarificar que a contribuição está na arquitetura desacoplada, não no tipo de teste.	T13
A	"description, motivation, and presentation of the approach could be improved"	Reescrever a Secção de Motivação para justificar a necessidade de separar o Planner do Assertion Agent, com exemplos reais de falha de um agente único.	T11
A	"does not address known challenges with respect to the dynamic nature of python"	Adicionar subsecção de Discussão sobre como o MARTA lida com tipagem dinâmica e comportamento em tempo de execução.	T14
A	"it remains fixed on the limitations of what it refers to as 'monolithic' approaches... ignores the complex (static) analysis they perform before prompting the LLM nor the different heuristics they apply... An open and honest confrontation of a purely LLM-based approach and those that apply a hybrid approach would have been more meaningful."	Reescrever a caracterização das abordagens "monolíticas"/híbridas: reconhecer a análise estática e heurísticas que ferramentas híbridas (ex: Pynguin) aplicam, e fazer uma comparação honesta LLM-puro vs. híbrido em vez de atacar uma versão simplificada.	T11, T1
A	"the work presented does not exploit the full potential of a multi-agent architecture to put in place a significant contribution to the community"	Demonstrar empiricamente, via ablation, como a colaboração entre agentes resolve problemas que um único agente não consegue em vez de o afirmar apenas no texto.	T5
A	"Its application for test generation in python, as presented here, is hence marginally novel"	Ancorar a Novelty no ablation (desacoplado vs. monolítico, mesmo modelo, com significância): a sinergia entre RAG, ReAct e Outer loop guiado por coverage é validada por dados, não só pela narrativa.	T5, T11
A	"should have included additional baselines, e.g., CoverUp, or event the traditional pynguin"	Adicionar Pynguin (limitações das abordagens tradicionais) e CoverUp/ChatTester (baselines LLM do estado da arte).	T1
A	"coverage appear to be better than the ones reported in this paper... The paper does not discuss these results."	O revisor compara com o estudo do Pynguin [1] nos mesmos sujeitos. Discutir o gap face ao Pynguin e, à parte, explicar a discrepância da baseline TEST4PY (88% reportados vs. 58% reproduzidos no mesmo setup), justificada pelo modelo 16B. Apresentar tabela "reportado vs. reproduzido".	T1
A	"executions are not repeated, to account for inherent non-determinism... not backed by any statistical analysis"	Executar as pipelines 3 a 5 vezes, extrair médias/medianas e aplicar testes de significância (ex: Wilcoxon). Nota: com 10 projetos o poder estatístico é limitado.	T3
A	"in Figure 2, we don't know the maximum values... how is the 'hallucinated' assertions detected?"	Atualizar Fig. 2 com eixos visíveis (máximos) e incluir parágrafo explícito sobre a metodologia de deteção de alucinações.	T8
A	"There is also no reporting of run-times (e.g., in minutes), nor the number of LLM prompts (e.g., number of tokens)"	Compilar rigorosamente estes dados. Como as runs originais foram divididas entre o PC local e o Deucalion, as novas execuções terão recolha estrita de Custo/Tokens e Tempo.	T4
A	"results about code coverage are given in statement coverage, but for the ablation study branch coverage is also provided"	Normalizar as métricas: reportar consistentemente Statement e Branch Coverage em todas as secções.	T7
A	"clearly present the details of the selected subjects, a table with	Criar tabela detalhada dos 10 projetos (LoC, módulos, funções, branches,	T6

	details such as number of lines/branches... budget settings... timeout settings... two values for the temperature"	complexidade) + secção "Experimental Setup" com timeouts, budgets e justificação das temperaturas (responder à nota de que valores mais altos, ex. 0.6, são tipicamente recomendados).	
A	"why the coverage driven aspect is not part of the initial test design phase... included in the prompt of the Planner Agent? Have authors already considered this aspect and discarded it?"	Justificação arquitetural: pedir 100% de coverage a priori causa alucinações severas; daí o feedback loop dinâmico posterior. Indicar explicitamente que a alternativa foi considerada e descartada.	T15
A	"the use of a single LLM is also problematic. Authors should consider adding at least one more LLM, with a different architecture and parameter size"	Avaliar com pelo menos mais um modelo, de arquitetura/tamanho diferentes (ex: OpenRouter, Claude/GPT). Objetivo: provar que o ganho arquitetural se mantém entre escalas e não que o modelo grande "compensa".	T2
A	"(Verifiability) does not provide much details regarding the implementation itself besides stating the LLM used... describe the technological choices made in the implementation and its potential impact on the results"	Adicionar subsecção de Implementação: stack e bibliotecas (pycg, coverage.py, mutmut, pytest-json-report), modelo de embeddings do RAG, e o impacto destas escolhas.	T9
A	"The inner/outer loop concept is not clearly discussed, also in relation to Figure 1"	Redesenhar a Figura 1 e reescrever a explicação, separando visualmente o Self-Healing (Inner) do Coverage-Driven (Outer).	T8
A	"Not sure what value Listing 1 adds... remove it... the data availability statement is too much"	Remover o Listing 1 e encurtar a Data Availability Statement, ganhando espaço para a estatística e as métricas em falta.	T10
A	"failing tests that could not be repaired after N attempts are excluded... what comes of these failing tests in the end?"	Detalhar a Quarentena (confirmada no código, testcase_react.py): os testes irreparáveis são movidos para test_quarantine, isolados para não causarem Test Pollution nem falsos positivos no Mutmut.	T16
A	"the ablation could have included interesting aspects, such as the usefulness of RAG"	Adicionar coluna no Ablation comparando a ferramenta completa com uma versão com RAG desativado.	T5
A	"instances a class may have different methods/fields at runtime. It is also possible to implement modules in C/C++... How does the presence/absence of type hints impact MARTA?"	Subsecção de Discussão sobre limitações face a extensões C/C++ e o impacto da (in)existência de Type Hints na taxa de sucesso.	T14
B	"Mean statement coverage of 65% and mutation score of 36% sounds like quite a poor generated test suite"	Contextualizar a dificuldade dos projetos e enquadrar como ganho relativo sobre a baseline no mesmo modelo; mostrar que com modelos de fronteira os valores absolutos sobem sem fazer disso o argumento principal.	T2
B	"There is no qualitative inspection of the generated tests and no comparison against existing developer-written tests"	Introduzir um Case Study qualitativo comparando um teste complexo humano vs. gerado pela MARTA, abordando legibilidade e manutenibilidade.	T17
B	"What justifies the 10 Python projects as good subjects? ... concerns about how well MARTA would generalize to medium- or large-scale projects"	Justificar a complexidade interna dos 10 projetos (ex: uso intensivo de mocks) e/ou adicionar um dataset maior (ex: SWT-bench).	T18
B	"What is novel beyond combining RAG, ReAct, coverage-driven iteration, and multi-agent prompting?"	Provar via ablation o valor do desacoplamento e a resolução ativa de Test Pollution e separação de domínios (Planeamento vs. Sintaxe), em vez de reframing narrativo.	T5
B	"how does the framework distinguish between tests failing due to genuine bugs... versus failing due to problems with the test itself? It seems MARTA might overfit tests to pass"	Atualmente o código NÃO distingue um teste mal gerado de um teste bem feito sobre código com bugs o self-healing loop faz o teste passar quer o código esteja certo ou errado (problema dos testes de regressão). DECISÃO DA PROFESSORA: (OPÇÃO 1) declarar como limitação na Discussão; ou (OPÇÃO 2) implementar um filtro que NÃO repara falhas de AssertionError sobre o output esperado (potencial bug), reparando só falhas de setup/runtime (ImportError, TypeError de fixture). Ver T12.	T12
B	"how does MARTA ensure that the generated tests are actually doing anything useful... there needs to be some justification for using it [coverage] as a signal"	Demonstrar correlação estatística entre o aumento de coverage do Outer Loop e ganhos no Mutation Score. Verificar primeiro nos dados atuais se a correlação se sustenta.	T19
B	"strong claims that search-based tools like Pynguin are 'completely blind,' yet there is no evidence... see Pynguin"	Remover a afirmação infundada ("completely blind") e adicionar o Pynguin à tabela comparativa de baselines.	T1, T11
B	"claim to measure computational effort in terms of total runtime and average token consumption... neither are reported"	Fornecer as tabelas exatas de Consumo de Tokens e Tempos de Execução.	T4

B	"phrases like 'cognitive overload' and 'fatigue'... 'staggering' and 'unlocked the architecture's full potential' make the paper read more like advocacy"	Revisão de copywriting científico: remover antropomorfismos e adjetivos hiperbólicos, substituindo-os por linguagem técnica neutra.	T11
C	"comparison is limited to a single tool (TEST4PY) that also serves as the source of MARTA's Phase 1... more accurately an ablation than a competitive evaluation"	Comparar contra frameworks totalmente independentes (CoverUp, ChatTester). Sem baselines independentes, toda a avaliação é questionável.	T1
C	"all experiments use DeepSeek-Coder-V2 16B, a relatively weak model... run the monolithic baseline with a frontier model (e.g., GPT-5 or Claude 3.6)"	Executar baseline e MARTA num LLM de fronteira para provar que a melhoria vem da arquitetura e não de compensar um LLM fraco. Dependência: acesso a OpenRouter/cloud.	T2
C	"Assertion Deletion Quantification... made without any supporting data. The paper does not report how many baseline tests underwent assertion deletion"	O revisor considera a afirmação creível; falta a prova numérica no artigo. Extrair dos logs e reportar: n°/% de testes da baseline com asserts apagados, fração da coverage atribuível a esses "testes ocos", e se o gap de mutation score é proporcional à taxa de deleção. Tom factual, sem acusação.	T20
C	"Why not use a more popular testing benchmark like SWT-bench?"	Adotar o SWT-bench ou fundamentar rigorosamente a escolha do dataset atual.	T18

Tarefas Consolidadas e Estimativas de Esforço

Esforço humano em dias úteis. Várias tarefas resolvem mais do que um comentário (ver coluna "Comentários").

Tarefa	Descrição	Comentários	Esforço estimado	Dependências / Notas
T1	Baselines independentes (Pynguin, CoverUp, ChatTester)	A8, A9, C1, B7, A5	Difícil estimar	Instalar/configurar/correr 3 ferramentas nos 10 projetos. Depende de compute. Ponto mais crítico do paper.
T2	Modelo de fronteira / multi-LLM (baseline + MARTA)	A16, C2, B1	2–4 dias	Depende de acesso/custo OpenRouter ou cloud. Decisivo para provar a tese arquitetural. Não sei se fazendo tudo o resto continuaria a fazer sentido esta comparação apenas entre estas duas
T3	Repetição de runs (3–5×) + análise estatística (Wilcoxon)	A10	Difícil estimar	Maioria é tempo de máquina. Poder estatístico limitado (n=10).
T4	Instrumentação de custo (runtime + tokens)	A12, B8	0,5–1 dia	Recolhido durante as re-execuções de T1–T3.
T5	Ablation expandido (RAG on/off, desacoplado vs monolítico, etc)	A6, A7, A21, B4	Difícil estimar	É a prova empírica da Novelty. Inclui re-execução de variantes.
T6	Tabela de subjects + secção Experimental Setup	A14	1–1,5 dias	LoC, funções, branches, timeouts, budgets, temperaturas.
T7	Normalização de métricas (Statement + Branch)	A13	0,5–1 dia	Consistência em todas as secções.
T8	Figuras (Fig.1 inner/outer; Fig.2 eixos + método de alucinações)	A11, A18	1–2 dias	—
T9	Secção de Implementação (verifiability)	A17	~0,5 dia	Stack, bibliotecas, embeddings do RAG.
T10	Remover Listing 1 + encurtar Data Availability	A19	<0,5 dia	Liberta espaço para estatística/métricas.
T11	Reescrita: Motivação + posicionamento honesto monolítico/híbrido + remover hipóteses/antropomorfismos	A3, A5, A7, B7, B9	2–3 dias	Inclui remover "completely blind".
T12	Mecanismo bug-real vs teste-mau	B5	Opção 1: ~0,5 dia (texto) / Opção 2: 2–4 dias (implementar + validar)	DECISÃO PENDENTE (Opção 1 ou 2).
T13	Limitação dos testes de regressão (texto)	A2	~0,5 dia	Pode fundir-se com T11/T12.

T14	Discussão da natureza dinâmica do Python (tipagem, runtime, C/C++, type hints)	A4, A22	1–1,5 dias	—
T15	Justificações arquiteturais (coverage não no Planner inicial)	A15	~0,5 dia	—
T16	Documentar Quarentena / handling de failing tests	A20	~0,5 dia	Código já existe (testcase_react.py).
T17	Case study qualitativo (humano vs MARTA)	B2	1–2 dias	Aborda também legibilidade/manutenibilidade.
T18	Dataset maior / SWT-bench	B3, C4	Adotar: 5–10 dias / Justificar: ~0,5 dia	Decisão estratégica.
T19	Correlação coverage → mutation score	B6	~1 dia	Testar primeiro nos dados atuais.
T20	Quantificação de assertion deletion na baseline	C3	1–2 dias	Extração de logs + análise.